

JURIX 2026 — proposition de deux articles

Valoriser l'annotation thématique des *Terms of Service* et sa mise en graphe pour la **détection d'anomalies**

Ahmed El Azhar Jebbari • dir. Jean-Charles Lamirel • LORIA, Université de Lorraine • août 2026

🔗 **Fil conducteur.** Le but de la thèse est de **détecter les anomalies** des contrats ; CLAUDETTE en est la base de référence reconnue (la *clause abusive*, au sens de la directive 93/13/CEE, = l'anomalie). Nos **annotations thématiques multi-annotateurs** (clauses, thèmes, certitude) sont le **socle** qui rend cette détection possible, structurée et explicable. Les deux articles se suivent naturellement : **A produit et publie la ressource**, **B l'exploite pour détecter les anomalies** — ensemble, ils avancent le cœur de la thèse *tout en* produisant deux publications.

🏛 JURIX en bref

- **Quoi** : conférence **européenne de référence en IA & Droit** (*Foundation for Legal KB Systems*) ; actes chez **IOS Press**, série FAIA.
- **Quand / où** : 39^e édition, **Toulouse (IRIT)**, **8–10 déc. 2026**.
- **Public** : communauté IA & Droit, exigeante sur l'**ancrage juridique** et la **reproductibilité**.
- **Soumission** : abstract ~**28 août** • papier ~**5 sept.** (EasyChair, *single-blind* — pas d'anonymisation).
- **Formats** : long ≤ 10 p. ($\approx 20\%$ acc.) • short ≤ 5 p. • poster ≤ 2 p.
- **Choix stratégique** : *short/poster* accessibles $\Rightarrow$ publication très probable pour un travail solide.
- ✓ **Pourquoi nous y sommes chez nous** : la détection de clauses abusives dans les ToS (CLAUDETTE : Lippi, Lagioia, Ruggeri, Galassi...) est une **lignée native de JURIX**. Notre travail s'y inscrit directement, avec un angle neuf.

📖 Deux articles complémentaires

A Ressource (long)

CLAUDETTE-Themes — enrichissement thématique multi-annotateur d'Unfair-ToS

🔗 ABSTRACT (candidat)

Nous enrichissons CLAUDETTE/UNFAIR-ToS : des étiquettes d'abusivité au niveau de la phrase, nous passons à une annotation thématique de clauses, multi-label (≈ 20 thèmes juridiques, certitude, justification), produite indépendamment par trois annotateurs formés, en anglais et en français. Nous mesurons l'accord inter-annotateur multi-label (α de Krippendorff, distance MASI, par thème) et publions un **gold** qui préserve le désaccord — version arbitrée, votes bruts et soft labels — avec des baselines Legal-BERT. La ressource et son protocole de résolution de conflits sont réutilisables.

Contribution

- Comble une **limite reconnue** de CLAUDETTE (grain phrase $\rightarrow$ clause, multi-label).
- **Ressource réutilisable** — JURIX valorise explicitement les *datasets*.
- **Protocole de gold** transparent (cascade + désaccord préservé) = apport méthodologique.

📌 Valorise le travail d'annotation.

B Graphe (short $\rightarrow$ long)

Hypergraph Co-Occurrence Anomalies — découvrir les clauses abusives par graphe

🔗 ABSTRACT (candidat)

Nous représentons chaque document de conditions d'utilisation comme un hypergraphe clause-thèmes, construit à partir des annotations thématiques multi-label, et posons la **découverte de clauses abusives** comme une **détection d'anomalies de graphe** non supervisée : une combinaison de thèmes juridiques rare constitue une anomalie candidate. Nous évaluons les hyperarcs anormaux contre les étiquettes d'abusivité de CLAUDETTE (precision@k, AUC-PR) — et non par la seule rareté —, avec des baselines peu profondes et profondes, et mesurons par ablation le coût d'une couche déontique prédite (bruitée). Une détection relationnelle et explicable, bâtie sur la ressource A.

Contribution

- Détection d'anomalies **relationnelle et explicable** (pas phrase par phrase).
- **Niche inédite** : hypergraphe multi-label sur ToS, ancré sur CLAUDETTE.
- **Construit sur la ressource A** $\Rightarrow$ chaîne cohérente qui sert la thèse.

📌 Valorise la détection d'anomalies.

🔗 **Rigueur & positionnement.** Ancrage **protection du consommateur** (dir. 93/13/CEE) et dialogue avec la lignée CLAUDETTE (Lippi, Lagioia, Ruggeri, Galassi). Accord multi-label mesuré par α -MASI + Gwet AC (robuste aux classes rares) ; **baselines** et **analyse d'erreurs** ; **désaccord préservé** (répond à Braun 2023, *AI & Law*). Reproductibilité : corpus, protocole et prompts publiés.

🕒 Faisabilité en août & ressources en place

Les données arrivent en août ; l'essentiel est ensuite de la **mise en forme** et de la **rédaction**.

mi-août annotations 3×50 ToS $\rightarrow$ fin août α -MASI + gold + baselines $\rightarrow$ ~28 août abstracts $\rightarrow$ ~5 sept. papiers

📋 Déjà en place

- Corpus **50 ToS** annotés, **EN + FR** (traduits phrase à phrase, alignés 1 : 1).
- Plateforme **Pactiva** + **moteur de gold en cascade** (arbitrage tracé) codé et testé.
- **Legal-BERT** (open-weights, sans LLM) + code de segmentation/embeddings de la thèse.
- Métriques d'accord (α -MASI, Gwet AC) et **export deux couches** outillés.

🎯 Le filet (dé-risque)

- **A est sûr** : données présentes en août, méthodes sur étagère, surtout de la rédaction.
- **B n'est jamais bloquant** : soumis en **short** (preuve de concept) ou glissé en 2027.
- Arbitrage cadré sur un **échantillon stratifié** si le volume l'exige.
- **Compute modeste** (fine-tuning Legal-BERT + petit graphe), sans dépendance externe.

🚩 **Proposition.** Soumettre à JURIX 2026 **A (long)** + **B (short)**. **A** valorise les *thèmes* (le travail d'annotation), **B** les *graphes* (la détection d'anomalies) ; les deux **avancent le cœur de la thèse**. 🕒 **Prochaine étape** : établir l'état réel de la campagne (nombre de ToS multi-annotés / arbitrés) pour verrouiller le périmètre et le calendrier.